


1.什么是参数

在机器学习中，我们经常使用一个模型来描述生成观察数据的过程。例如，我们可以使用一个随机森林模型来分类客户是否会取消订阅服务（称为流失建模），或者我们可以用线性模型根据公司的广告支出来预测公司的收入（这是一个线性回归的例子）。每个模型都包含自己的一组参数，这些参数最终定义了模型本身。

我们可以把线性模型写成 $y = mx + c$ 的形式。在广告预测收入的例子中， x 可以表示广告支出， y 是产生的收入。 m 和 c 则是这个模型的参数。这些参数的不同值将在坐标平面上给出不同的直线（见下图）。



2.参数估计的方法

就是根据样本统计量的数值对总体参数进行估计的过程。根据参数估计的性质不同，可以分成两种类型：点估计和区间估计。

点估计就是用样本统计量的某一具体数值直接推断未知的总体参数。例如，在进行有关小学生身高的研究中，随机抽取1000名小学生并计算出他们的平均身高

为1.45米。如果直接用这个1.45米代表所有小学生的平均身高，那么这种估计方法就是点估计。

而对总体参数进行点估计常用的方法有两种：矩估计与最大似然估计，其中最大似然估计就是我们实际中使用非常广泛的一种方法。

按这两种方法对总体参数进行点估计，能够得到相对准确的结果。如用样本均值 \bar{X} 估计总体均值，或者用样本标准差 S 估计总体标准差 σ 。

但是，点估计有一个不足之处，即这种估计方法不能提供估计参数的估计误差大小。对于一个总体来说，它的总体参数是一个常数值，而它的样本统计量却是随机变量。当用随机变量去估计常数值时，误差是不可避免的，只用一个样本数值去估计总体参数是要冒很大风险的。因为这种误差风险的存在，并且风险的大小还未知，所以，点估计主要为许多定性研究提供一定的参考数据，或在对总体参数要求不精确时使用，而在需要用精确总体参数的数据进行决策时则很少使用。

区间估计就是在推断总体参数时，还要根据统计量的抽样分布特征，估计出总体参数的一个区间，而不是一个数值，并同时给出总体参数落在这一区间的可能性大小，概率的保证。还是举小学生身高的例子，如果用区间估计的方法推断小学生身高，则会给出以下的表达：根据样本数据，估计小学生的平均身高在1.4~1.5米之间，置信程度为95%，这种估计就属于区间估计。

3. 概率与统计的区别

概率 (probability) 和统计 (statistics) 看似两个相近的概念，其实研究的问题刚好相反。

概率研究的问题是，已知一个模型和参数，怎么去预测这个模型产生的结果的特性（例如均值，方差，协方差等等）。举个例子，我想研究怎么养猪（模型是猪），我选好了想养的品种、喂养方式、猪棚的设计等等（选择参数），我想知道我养出来的猪大概能有多肥，肉质怎么样（预测结果）。

统计研究的问题则相反。统计是，有一堆数据，要利用这堆数据去预测模型和参数。仍以猪为例。现在我买到了一堆肉，通过观察和判断，我确定这是猪肉（这

就确定了模型。在实际研究中，也是通过观察数据推测模型是 / 像高斯分布的、指数分布的、拉普拉斯分布的等等），然后，可以进一步研究，判定这猪的品种、这是圈养猪还是跑山猪还是网易猪，等等（推测模型参数）。

一句话总结：概率是已知模型和参数，推数据。统计是已知数据，推模型和参数。

显然，对于最大似然估计，最大后验估计，贝叶斯估计来说，都属于统计的范畴。

4.最大似然估计(maximum likelihood estimates, MLE)

前文提到，最大似然估计(maximum likelihood estimates, MLE)是实际中使用非常广泛的一种方法，用我们老师的一句最简单的话来总结最大似然估计，就是“谁大像谁”。

说到最大似然估计与最大后验估计，最好的例子自然就是抛硬币了。本文也不免俗，同样以抛硬币作为例子。

于是我们拿这枚硬币抛了10次，得到的数据X是：反正正正反反正正反。我们想求的正面概率 θ 是模型参数，而抛硬币模型我们可以假设是二项分布。

在概率论和统计学中，二项分布 (Binomial distribution) 是n个独立的是/非试验中成功的次数的离散概率分布，其中每次试验的成功概率为p。这样的单次成功/失败试验又称为伯努利试验。实际上，当n = 1时，二项分布就是伯努利分布。

伯努利分布 (Bernoulli distribution，又名两点分布或者0-1分布，是一个离散型概率分布，为纪念瑞士科学家雅各布·伯努利而命名。)若伯努利试验成功，则伯努利随机变量取值为0。记其成功概率为 $p(0 \leq p \leq 1)$, 失败概率为 $q=1-p$ 。

对于伯努利分布来说：

概率质量函数为：

$$f(x) = p^x(1-p)^{1-x} = \begin{cases} pq & \text{if } x=1, \\ 0 & \text{if } x=0. \end{cases}$$

期望为：

$$E[X] = \sum_{i=0}^1 x_i f(x) = 0 + p = p$$

方差为：

$$\text{var}[X] = \sum_{i=0}^1 (x_i - E[X])^2 f(x) = (0-p)^2(1-p) + (1-p)^2p = p(1-p) = pq$$

而如果 $X \sim B(n, p)$ (也就是说， X 是服从二项分布的随机变量)

一般的二项分布是 n 次独立的伯努利试验的和。它的期望值和方差分别等于每次单独试验的期望值和方差的和：


$$\mu_n = \sum_{k=1}^n \mu = np, \sigma^2_n = \sum_{k=1}^n \sigma^2 = np(1-p).$$

回到抛硬币的例子，出现实验结果 X 的似然函数是什么呢？

$$f(X, \theta) = \theta^x (1-\theta)^{1-x}$$

需要注意的是，上面只是个关于 θ 的函数。而最大似然估计，很明显是要最大化这个函数。

可以看一下这个函数的图像：



容易得出，在 $\theta=0.7$ 时，似然函数能取到最大值。

当然实际中我们一般不会画图，而是通过更为简洁的数学手段来处理。

首先我们取对数似然函数，这样更方便后续的数学运算：

$$\ln(f(X, \theta)) = \ln(7\theta(1-\theta)^3) = 7\ln(\theta) + 3\ln(1-\theta)$$

对对数似然函数求导：

$$\ln'(f(X, \theta)) = 7/\theta - 3/(1-\theta)$$

令导数为0：

$$7/(1-\theta) - 3/\theta = 0$$

最终求得：

$$\theta = 0.7$$

这样，我们已经完成了对

的最大似然估计。即，抛10次硬币，发现7次硬币正面向上，最大似然估计认为正面向上的概率是0.7。是不是非常直接，非常简单粗暴？没错，就是这样，谁大像谁！

说到这里为止，可能很多同学不以为然：你这不坑爹嘛？只要硬币一枚正常硬币，不存在作弊情况，正面朝上的概率必然为0.5么，你这怎么就忽悠我们是0.7呢。OK，如果你这么想，恭喜你，那你就天然包含了贝叶斯学派的思想！我们所谓的正常硬币向上的概率为0.5，就是贝叶斯里的先验概率。

5.最大后验估计(maximum a posteriori estimation)

上面的最大似然估计MLE其实就是求一组能够使似然函数最大的参数，即

$$\theta^{\wedge}_{\text{ML}}(x) = \operatorname{argmax}_{\theta} f(x|\theta)$$

如果我们把问题稍微弄复杂一点，如果这个参数 θ 有一个先验概率呢？比如上面的例子中，实际生活经验告诉我们，硬币一般都是均匀的，也就是 $\theta=0.5$ 的概率最大，那么这个参数该怎么估计？

这个时候就用到了我们的最大后验概率MAP。MAP的基础是贝叶斯公式：

$$p(\theta|x) = p(x|\theta) \times p(\theta)P(x)$$

其中， $p(x|\theta)$ 就是之前讲的似然函数， $p(\theta)$ 是先验概率，是指在没有任何实验数据的时候对参数 θ 的经验判断，对于一个硬币，大概率认为他是正常的，正面的概率为0.5的可能性最大。


MAP优化的就是一个后验概率，即给定了观测值以后使后验概率最大：

$$\theta^{\wedge}_{\text{MAP}} = \operatorname{argmax}_{\theta} p(\theta|x) = \operatorname{argmax}_{\theta} p(x|\theta) \times p(\theta)P(x) = \operatorname{argmax}_{\theta} p(x|\theta) \times p(\theta)$$

从上面公式可以看出， $p(x|\theta)$ 是似然函数，而 $p(\theta)$ 就是先验概率。对其取对数：

$$\begin{aligned} \operatorname{argmax}_{\theta} p(x|\theta) \cdot p(\theta) &= \operatorname{argmax}_{\theta} \log \prod_{i=0}^n p(x_i|\theta) p(\theta) = \operatorname{argmax}_{\theta} \sum_i \log(p(x_i|\theta) \\ &\quad p(\theta)) = \operatorname{argmax}_{\theta} \sum_i \log(p(x_i|\theta) + \log(p(\theta))) \end{aligned}$$

通过MAP最终的式子不难看出，MAP就是多个作为因子的先验概率 $P(\theta)$ 。这个 $p(\theta)$ 可以是任何的概率分布，比如高斯分布，比如也可以是 β 分布。比如 $\beta(5,2)$ 的概率分布图如下：



如果将这个概率分布作为 $p(\theta)$ ，那么我们在还未抛硬币前，便认为 θ 很可能接近于0.8，而不大可能是个很小的值或是一个很大的值。换言之，我们在抛硬币前，便估计这枚硬币更可能有0.8的概率抛出正面。

那么问题就来了，为什么我们要用 β 分布来描述先验概率呢？

首先一点，通过调节 Beta 分布中的 a 和 b ，你可以让这个概率分布变成各种你想要的形状！Beta 分布已经很足够表达我们事先对 θ 的估计了。

更重要的一点是，如果使用Beta 分布，会让之后的计算更加方便。因为有如下结论：

$p(\theta)$ 是个Beta分布，那么在观测到“ $X = \text{抛10次硬币出现7次正面}$ ”的事件后， $p(\theta|X)$ 仍然是个Beta分布，只不过此时概率分布的形状因为有了观测事件

而发生了变化！此时有

$$p(\theta|X) = \text{Beta}(\theta|a+3, b+2)$$

换句话说，数据观测前后，对 θ 的估计的概率分布均为 Beta 分布，这就是为什么使用 Beta 分布方便我们计算的原因。当我们得知 $p(\theta|X) = \text{Beta}(\theta|a+3, b+2)$ 后，只要根据 Beta 分布的特性，得出 θ 最有可能等于多少了。即 θ 等于多少时，观测后得到的 Beta 分布有最大的概率密度）。

到此为止，我们可以得到“共轭性”的真正含义了！后验概率分布（正比于先验和似然函数的乘积）拥有与先验分布相同的函数形式。这个性质被叫做共轭性（Conjugacy）。共轭先验（conjugate prior）有着很重要的作用。它使得后验概率分布的函数形式与先验概率相同，因此使得贝叶斯分析得到了极大的简化。例如，二项分布的参数之共轭先验就是我们前面介绍的 Beta 分布。多项式分布的参数之共轭先验则是 Dirichlet 分布，而高斯分布的均值之共轭先验是另一个高斯分布。

总的来说，对于给定的概率分布 $p(X|\theta)$ ，我们可以寻求一个与该似然函数 $p(X|\theta)$ 共轭的先验分布 $p(\theta)$ ，如此一来后验分布 $p(\theta|X)$ 就会同先验分布具有相同的函数形式。而且对于任何指数族成员来说，都存在有一个共轭先验。

6. 贝叶斯估计

贝叶斯估计是在MAP上做进一步拓展，此时不直接估计参数的值，而是允许参数服从一定概率分布。回忆下贝叶斯公式：

$$p(\theta|x) = p(x|\theta) \times p(\theta)P(x)$$

现在我们不要求后验概率最大，这个时候就要求 $p(X)$ ，即观察到的 X 的概率。一般来说，用全概率公式可以求 $p(X)$

$$p(X) = \int p(X|\theta)p(\theta)d\theta$$

那么如何用贝叶斯估计来预测呢？如果我们想求一个值 x' 的概率，可以用下面的方法

$$p(\hat{x}|X) = \int_{\theta \in \Theta} p(\hat{x}|\theta)p(\theta|X)d\theta = \int_{\theta \in \Theta} p(\hat{x}|\theta) \frac{p(X|\theta)p(\theta)}{p(X)}d\theta$$

7. 什么时候 MAP 估计与最大似然估计相等？

当先验分布均匀之时，MAP 估计与 MLE 相等。直观讲，它表征了最有可能值的任何先验知识的匮乏。在这一情况中，所有权重分配到似然函数，因此当我们把先验与似然相乘，由此得到的后验极其类似于似然。因此，最大似然方法可被看作一种特殊的 MAP。

如果先验认为这个硬币是概率是均匀分布的，被称为无信息先验(non-informative prior)，通俗的说就是“让数据自己说话”，此时贝叶斯方法等同于频率方法。

随着数据的增加，先验的作用越来越弱，数据的作用越来越强，参数的分布会向着最大似然估计靠拢。而且可以证明，最大后验估计的结果是先验和最大似然估计的凸组合。

参考文献：

1. <https://blog.csdn.net/baimafujinji/article/details/51374202>
2. <https://blog.csdn.net/yt71656/article/details/42585873>
3. <https://www.jiqizhixin.com/articles/2018-01-09-6>
4. <https://zh.wikipedia.org/zh-hans/>二項分佈
5. <https://zh.wikipedia.org/wiki/>伯努利分布
6. Pattern Recognition And Machine Learning